

Calibración y estrategia

Clase 4 · Del score a las decisiones de negocio

Martes 8 de septiembre de 2026 · Modelador de Riesgo de Crédito – Edición agosto-septiembre 2026

Camilo González · Academia Bayes en colaboración con Nikodym Advisory

Dónde estamos: el score ordena – falta que diga la verdad



El jueves cerramos un scorecard de 8 variables con Gini 0,757 / 0,698 / 0,675. Hoy lo convertimos en decisiones: PD calibrada, bandas y un punto de corte con números.

- ▶ Primero, cerramos la construcción del score: de los β a los puntos, reason codes, monotonía y las decisiones que la herramienta no resuelve sola.
- ▶ Después, la idea que ordena la clase: un score puede ordenar perfecto y aun así mentir en el nivel.
- ▶ El plan: calibrar la PD → bandas de riesgo → punto de corte (aprobación vs pérdida) → swap-set.
- ▶ Todo lo de hoy es material directo de su Entrega 2: hoy se habilita la parte B del Lab 2.
 - Fechas: la E2 (Lab 2 completo, partes A y B) vence el DOMINGO 13 · la próxima clase es el JUEVES 10.

ANTES DE EMPEZAR

Lo que el jueves quedó «para la otra clase»

Del scorecard a las decisiones que requieren criterio: puntos, reason codes, monotonía, parámetros, missing, familias y coherencia con el negocio.

Cómo se convierte un tramo en puntos

Puntos del tramo = base común + aporte del tramo

El aporte depende del peso de la variable y del WoE del tramo

TRAMO FAVORABLE · WoE 4,26

$$\begin{array}{ccc} \boxed{71,8} & + & \boxed{+43,3} & = & \boxed{115,1} \\ \text{base común} & & \text{el tramo suma puntos} & & \text{puntos del tramo} \end{array}$$

TRAMO RIESGOSO · WoE -1,23

$$\begin{array}{ccc} \boxed{71,8} & + & \boxed{-12,5} & = & \boxed{59,3} \\ \text{base común} & & \text{el tramo resta puntos} & & \text{puntos del tramo} \end{array}$$

La base no cambia. El WoE determina si el tramo suma o resta.

Detalle: aporte del tramo = $(-\beta \times \text{factor}) \times \text{WoE}$. En esta variable, $-\beta \times \text{factor} \approx 10,2$.

La cuenta completa para uso_tc_prom_12m ($\beta = -0,353$)

Atributo	WoE del tramo	pendiente $\times$ WoE (10,2 $\times$ WoE)	+ base (71,8)	Puntos
hasta 0,208	4,26	43,3	71,8	115,1
0,208 - 0,252	1,54	15,6	71,8	87,4
0,252 - 0,292	0,51	5,2	71,8	77,0
0,292 - 0,339	-0,09	-0,9	71,8	70,9
sobre 0,339	-1,23	-12,5	71,8	59,3

La misma cuenta para las otras 7 variables da las 41 filas del scorecard. La base es la misma para todas; la pendiente cambia con β : de 8,9 puntos por unidad de WoE en uso_tc_prom_3m a 26,7 en deuda_interna_max_3m. Por eso el rango de puntos y el coeficiente no ordenan igual: el rango también depende de cuánto se abre el WoE de cada variable.

El score es la suma de sus 8 tramos: solicitud S0030427

Variable	Valor del cliente	Tramo	WoE	Puntos
uso_linea_prom_12m	0,349	0,307 - 0,364	-0,12	70,1
meses_desde_mora_12m	13	= 13 (sin mora en 12 meses)	0,38	80,2
uso_tc_prom_12m	0,287	0,252 - 0,292	0,51	77,0
deuda_interna_max_3m	8,29 M	sobre 3,55 M	0,13	75,4
antiguedad_meses	55	29 - 59	-0,22	67,9
deuda_otras_prom_12m	11,50 M	sobre 5,71 M	1,30	101,4
carga_financiera	5,582	sobre 4,067	-0,87	61,4
uso_tc_prom_3m	0,294	0,294 - 0,365	-0,15	70,5
Suma de los 8 tramos = score				603,8 ≈ 604

604 puntos $\Leftrightarrow$ PD 1,7%: la misma información que el logit, en una escala que se explica tramo a tramo. Es el cliente «medio» de los tres de la demo; en producción la tabla se redondea a enteros y el score de cada solicitud sale de sumar 8 celdas de este scorecard.

Reason codes, la cuenta: solicitud S0027717, score 457

Variable	Puntos obtenidos	Máximo posible	Brecha	Motivo (los 3 mayores)
uso_tc_prom_12m	59,3	115,1	55,8	tarjeta de crédito cargada de forma sostenida
meses_desde_mora_12m	27,1	80,2	53,2	mora propia reciente
uso_linea_prom_12m	52,5	105,4	52,9	utilización de la línea sostenidamente alta el último año
deuda_otras_prom_12m	67,8	101,4	33,6	
uso_tc_prom_3m	62,3	90,1	27,8	
deuda_interna_max_3m	58,9	85,4	26,6	
carga_financiera	61,4	83,1	21,8	
antiguedad_meses	67,9	85,7	17,9	

Brecha = máximo de la variable – puntos obtenidos. Las tres brechas más grandes, ordenadas, son los reason codes: con esas tres frases se escribe la carta de rechazo (PD 73,9%). En el cliente de 740 puntos todas las brechas son ≈ 0 salvo una de 7: no hay motivo que dar.

La objeción, cerrada: monotonidad por contrato (1 de 2)

demo_c3_banco_austral.ipynb · §10 · a mano vs monotonidad por contrato (1 de 2)

```
> meses_desde_mora_12m
```

A MANO – binear() por cuantiles

NO monótona <-- el quiebre

= 13	80.2
(-inf, 2.0]	27.1
(2.0, 4.0]	54.5
(4.0, 7.0]	75.3
(7.0, 9.0]	52.7
(9.0, inf]	64.7

optbinning – monotonic_trend=auto_asc_desc

monótona OK

(-inf, 3.50)	36.4
[3.50, 12.50)	64.0
[12.50, inf)	79.1
Special	71.7
Missing	71.7

```
> deuda_interna_max_3m
```

A MANO – binear() por cuantiles

NO monótona <-- el quiebre

(-inf, 1128000.0]	73.6
(1128000.0, 1684400.0]	58.9
(1684400.0, 2363200.0]	71.8
(2363200.0, 3553600.0]	85.4
(3553600.0, inf]	75.4

optbinning – monotonic_trend=auto_asc_desc

monótona OK

(-inf, 1608000.00)	69.0
[1608000.00, 1962500.00)	70.7
[1962500.00, 2303500.00)	72.2
[2303500.00, 3677000.00)	74.0
[3677000.00, inf)	76.3
Special	71.7
Missing	71.7

Monotonidad por contrato (2 de 2)

Una secuencia puede ser perfectamente monótona y aun así ir en una dirección difícil de defender frente al negocio.

Tramo de deuda	Puntos
$(-\infty; \$1,61 \text{ MM})$	69,0
$[\$1,61; \$1,96 \text{ MM})$	70,7
$[\$1,96; \$2,30 \text{ MM})$	72,2
$[\$2,30; \$3,68 \text{ MM})$	74,0
$[\$3,68 \text{ MM}; +\infty)$	76,3

Más puntos = menor riesgo

La solución es monótona, pero contraintuitiva

- Los puntos suben con la deuda; por sí sola, la tabla interpreta más deuda como menor riesgo.
- Puede reflejar selección de aprobados, relación con el producto, una definición imperfecta o una señal real del portafolio.
- Primero se revisa la relación en HO/OOT y su explicación de negocio. Si no es defendible, se fija una tendencia acordada y se reestima, o se descarta la variable.

No se fuerza la dirección solo para que "se vea bien": se exige una justificación replicable y documentada.

¿Y si la herramienta hace todo sola? Tres experimentos

Experimento	Variables	Gini DEV	Gini HO	Gini OOT	Lectura
1 · Nuestro embudo, a mano (lo de hoy)	8	0,757	0,698	0,675	La referencia
2 · optbinning con NUESTRAS 8: binning óptimo y monótono	8	0,766	0,683	0,684	Empate ($\pm 0,01$): gana monotonía, no Gini
3 · optbinning con el pool de 94, eligiendo solo ($IV \geq 0,10$)	66	0,805	0,657	0,677	+5 pts en DEV, -4 en HO: señal de sobreajuste

Cuando el embudo está bien hecho, el binning óptimo no compra Gini: compra monotonía garantizada y trazabilidad. Sin embudo, aparece una señal de sobreajuste: mejora DEV y deteriora HO – y nadie defiende 66 reason codes en un comité. El dueño del embudo sigues siendo tú.

Decisiones que requieren intervención del modelador

La herramienta automatiza la búsqueda, pero estas decisiones cambian el significado, la estabilidad o el uso del score.

1 Binning

Regular granularidad, tamaño, monotonía y separación.

2 Missing

Entender el mecanismo antes de agrupar o asignar WoE.

3 Cobertura

Evitar que el modelo dependa de una sola dimensión de riesgo.

4 Familias

Controlar sustitutos temporales y redundancia condicional.

5 Disponibilidad

Usar solo información observable al momento de decidir.

6 Gobierno

Justificar, reestimar y validar cada override material.

Regla de gobierno: si una decisión manual puede cambiar variables, bins, puntos o población, debe quedar reproducible y documentada.


Granularidad del binning: separación mínima y número máximo de bins

`min_event_rate_diff` fija una diferencia absoluta. Compararla con la tasa global ayuda a evaluar si la exigencia es material.

Ejemplo ilustrativo · tasa global de malos = 8%

Muy exigente


gap mín. 4,0 pp · máx. 5 bins



Puede forzar 2 bins o dejar la combinación sin solución factible.

Equilibrado


gap mín. 1,5 pp · máx. 5 bins



Separa riesgo con tramos legibles y operables.

Muy permisivo

gap mín. 0,2 pp · máx. 8 bins



Puede crear tramos casi iguales y más inestables.

El resultado también depende de los pre-bins, tamaños mínimos, monotonía, significancia y forma observada.

Caso 1: una separación alta puede dejar solo dos bins

Ejemplo ilustrativo. Variable uso_linea_prom_12m, 4.000 observaciones, tasa global de malos de 8,0%

Configuración exigente

$\text{min_event_rate_diff} = 0,040$, $\text{max_n_bins} = 5$

Bin	Rango de uso	n	% malos
1	[0,00; 0,65)	3.000	5,8%
2	[0,65; 1,00]	1.000	14,6%

La exigencia descarta cortes intermedios. El modelo conserva la señal, pero oculta niveles de riesgo que podrían servir para explicar o definir políticas.

Configuración equilibrada

$\text{min_event_rate_diff} = 0,015$, $\text{max_n_bins} = 5$

Bin	Rango de uso	n	% malos
1	[0,00; 0,20)	1.000	3,2%
2	[0,20; 0,40)	1.000	5,6%
3	[0,40; 0,65)	1.000	8,6%
4	[0,65; 1,00]	1.000	14,6%

Lectura correcta: un gap alto puede reducir los cortes. Con otras restricciones también puede dejar el problema sin solución factible.

Caso 2: exceso de bins y poca separación

Ejemplo ilustrativo. Variable uso_tc_prom_12m, 3.500 observaciones, tasa global de malos de 6,0%

Solución fragmentada

Gap mínimo de 0,2 pp, máximo permitido de 8 bins

Bin	Rango de uso	n	% malos
1	[0,00; 0,10)	500	4,2%
2	[0,10; 0,20)	500	4,8%
3	[0,20; 0,30)	500	5,4%
4	[0,30; 0,40)	500	6,0%
5	[0,40; 0,52)	500	6,6%
6	[0,52; 0,65)	500	7,2%
7	[0,65; 1,00]	500	8,0%

Candidato para reestimar

Gap mínimo de 1,0 pp, máximo permitido de 4 bins

Bin	Rango de uso	n	% malos
1	[0,00; 0,20)	1.000	4,5%
2	[0,20; 0,40)	1.000	5,7%
3	[0,40; 0,65)	1.000	6,9%
4	[0,65; 1,00]	500	8,0%

Agrupar tramos cercanos simplifica la explicación. Después hay que comprobar que la nueva forma conserve señal y estabilidad en HO y OOT.

Un máximo alto permite más bins, pero no obliga al algoritmo a utilizarlos.

Missing y valores especiales: evidencia primero, negocio después

La tasa observada guía el tratamiento estadístico. El sentido de negocio define qué investigar y si hace falta una política adicional.

1 · Entender el origen

Separar causas: sin historia, no aplica, falla de captura o política anterior. Si -9 y -99 significan cosas distintas, no deben compartir código especial.



2 · Medir el comportamiento

Revisar n, tasa de malos, WoE y estabilidad en DEV, HO y OOT. Comparar el mecanismo, no solo el promedio.



3 · Fijar el tratamiento

Mantener un bin propio o unir solo con similitud estable. Si cambia la definición, volver a estimar y validar.

Política conservadora

No alterar el WoE para que "se vea peor". Mantener el tratamiento empírico y agregar una política externa, o imponer una restricción explícita y volver a estimar. En ambos casos se valida y documenta.

En producción, el missing usa exactamente el mapping definido al entrenar: bin/índice o WoE empírico, según la implementación.

Un missing puede mezclar clientes muy distintos

Ejemplo ilustrativo · meses desde la última mora

Agrupado, el missing parece favorable. Al separarlo, aparecen dos historias opuestas.

Grupo	Meses desde la mora	n	% malos
1	0 a 3 meses	450	18,4%
2	4 a 12 meses	800	10,3%
3	13 a 24 meses	950	6,7%
4	Más de 24 meses	1.100	3,9%
Missing	Agrupado	900	4,1%

¿Qué contiene el 4,1%?

–9 · Nunca tuvo mora

800 clientes · 2,5% de malos

–99 · Sin información de bureau

100 clientes · 17,0% de malos

$$(800 \times 2,5\% + 100 \times 17,0\%) \div 900 = 4,1\%$$

**Tratamiento: separar –9 y –99, conservar su significado y validar cada grupo en HO/OOT.
Agruparlos oculta el riesgo de los clientes sin información de bureau.**

Un modelo compacto todavía necesita cobertura y granularidad

Pocas variables no es un problema por sí solo. Lo es cuando dejan huecos en los drivers de riesgo o demasiados empates en el score.

Cobertura de drivers

Conducta

mora propia y externa

Endeudamiento

saldos, uso y exposición

Capacidad

ingreso, carga y estabilidad

Recencia e intensidad

cuándo y cuánto cambió

Granularidad del score

n° variables $\neq$ n° de puntos

No es mecánico: cuatro variables con varios bins pueden producir decenas de combinaciones.

Sí puede pasar: pocos drivers o bins gruesos generan muchos empates y poca resolución para puntos de corte

El objetivo: suficiente resolución operativa, no maximizar puntajes distintos por estética.

El score debe separar, mantenerse estable y ofrecer cortes útiles sin perder explicación del riesgo.

La correlación no basta: hay que revisar familias de variables

Tres variables de mora pueden sobrevivir al filtro y seguir contando casi la misma historia, sobre todo si cambian solo la ventana temporal.

Familia mora

mora_max_3m



mora_max_6m



mora_max_12m



Revisión conjunta

Aporte incremental: ¿agrega señal al resto?

Estabilidad: ¿mantiene bins, signo y efecto fuera de muestra?

Disponibilidad: ¿existe con la misma definición en producción?

Rol de negocio: ¿aporta un driver distinto o solo repite historia?



Decisión a nivel de familia

Conservar los representantes con mejor aporte y estabilidad.

Excluir la familia si el problema es común: fuga, disponibilidad, proxy o incoherencia.

Reestimar porque al sacar 12m puede entrar 6m o 3m.

La correlación lineal o por pares no detecta toda la redundancia condicional ni el reemplazo entre ventanas.

Un Gini alto no cierra la revisión del modelo

El modelo final también debe ser coherente con el producto, observable al decidir y defendible frente a validación.

Hipotecario sin variables hipotecarias

Puede predecir, pero la cobertura del producto queda débil. Revisar calidad y aporte de variables hipotecarias; si la brecha persiste, reconstruir o segmentar.

Cientes nuevos con historia interna

Si esa historia no existe al originar, hay inconsistencia temporal. Segmentar, usar fuentes disponibles o construir otro modelo.

Una variable “molesta” aunque rinda

Retirla solo por una razón explícita: fuga, proxy, inestabilidad, signo, costo, disponibilidad o política. Después, reestimar y medir impacto.

Preselección desde 3.000 variables

Es válida y necesaria, pero no invisible: inventario, reglas, conteos y motivos deben quedar trazables, aunque validación no revise una a una.

El Gini mide discriminación; la aprobación también revisa uso, explicación, reproducibilidad y monitoreo.

PARTE 1

De score a PD calibrada

Ordenar bien no basta: provisiones, precios y cupos se calculan con el NIVEL.

Ranking y nivel son dos promesas distintas



El Gini mide si el score ordena. La calibración mide si la PD dice la verdad.

- ▶ Para APROBAR/RECHAZAR con un punto de corte relativo, bastaría ordenar bien.
- ▶ Pero la PD alimenta decisiones absolutas: provisiones, pricing por riesgo, capital, apetito. Ahí un nivel corrido cuesta plata en serio.
- ▶ El intercepto del jueves ($\beta_0 = -3,03$) es, en la práctica, el log-odds de la tasa de malos de DEV: absorbe el nivel de SU muestra. Calibrar es, literalmente, mover el intercepto.
- ▶ Si la cartera de mañana no se parece a DEV – otro ciclo, otro mix – el ranking sobrevive, pero el nivel queda corrido.
 - Separar ranking de nivel es la idea que ordena toda la clase de hoy.

El nivel en Banco Austral: dónde clava y dónde miente

Muestra	n	PD media del modelo	Tasa observada	Sesgo (puntos porcentuales)
DEV (donde se ajustó)	3.322	4,97%	4,97%	0,00 – clava por construcción
HO (clientes nuevos)	1.397	5,17%	5,58%	–0,42
OOT (meses posteriores)	2.004	5,19%	5,94%	–0,75
TTD (bandeja de hoy)	8.585	5,79%	aún no observable	–

En DEV, con una logística sin ponderaciones y un intercepto libre, la media de la PD coincide con la tasa observada por la ecuación de primer orden; en este caso clava por construcción. Fuera de DEV el modelo subestima: la cartera se deterioró dentro de la ventana (las cosechas recientes vienen peores). Sesgo = PD media – tasa observada.

La muestra de calibración: reciente y con target maduro

Muestra PIT del caso: las últimas cuatro cosechas maduras (mar-jun 2025).

Cosecha	n	Malos	Tasa
2024-07	592	31	5,24%
2024-08	618	34	5,50%
2024-09	603	24	3,98%
2024-10	585	24	4,10%
2024-11	583	40	6,86%
2024-12	640	31	4,84%
2025-01	554	29	5,23%
2025-02	544	30	5,51%
2025-03 · PIT	488	34	6,97%
2025-04 · PIT	503	25	4,97%
2025-05 · PIT	505	30	5,94%
2025-06 · PIT	508	30	5,91%
Periodo PIT reciente	2.004	119	5,94%
Alternativa TTC	12 cosechas	–	5,42%
Modelo original en DEV	3.322	–	4,97%

Regla práctica: el periodo debe ser reciente, representativo y maduro. Si aún no terminó la ventana de desempeño, la tasa real está incompleta y no sirve para calibrar.

Calibración PIT: la receta completa en cuatro pasos

Comparamos predicción y realidad en la misma ventana. Después movemos solo el intercepto.



El promedio calza por construcción en esta muestra. La prueba real viene después: aplicar el ajuste a otro periodo y revisar nivel, pendiente y estabilidad.

El ajuste del intercepto: aproximación y solución exacta

A todos los clientes se les suma el mismo δ en el logit: cambia el nivel, pero no el orden.

$$\text{PD calibrada}_i = \sigma[\text{logit}(\text{PD}_i) + \delta]$$

Estimación rápida

$$\delta \approx \text{logit}(5,94\%) - \text{logit}(5,19\%)$$

$$\delta \approx +0,143$$

Optimización exacta • usada

$$\text{promedio}\{\sigma[\text{logit}(\text{PD}_i) + \delta]\} = 5,94\%$$

$$\delta = +0,177$$

La solución exacta usa todas las PD individuales. Como la transformación es curva, no da exactamente lo mismo que ajustar solo con los dos promedios.

Qué cambia después de calibrar al periodo reciente


OOT queda en 5,94% por construcción. DEV y HO sirven como contraste, no como objetivo del ajuste.

Muestra	PD antes	PD PIT	Observada	Brecha antes	Brecha después
DEV	4,97%	5,70%	4,97%	0,00 pp	+0,74 pp
HO	5,17%	5,92%	5,58%	-0,42 pp	+0,34 pp
OOT · calibración	5,19%	5,94%	5,94%	-0,75 pp	0,00 pp
Periodo posterior	–	–	Pendiente	–	Validar

**Lectura correcta: la mejora en OOT no es validación independiente, porque OOT fue usado para calibrar.
El ajuste debe probarse en una cosecha posterior ya madura.**

Después del ajuste PIT: tasa real y PD por mes

El promedio mar-jun calza en 5,94%, pero cada cosecha puede quedar por encima o por debajo.




mar-jun 2025
Promedio real = PD PIT = 5,94%

Brecha absoluta media mensual: 0,67 pp. Calibrar el promedio del periodo no obliga a acertar cada mes.

PIT y TTC: dos objetivos distintos

En esta presentación usamos PIT. TTC queda como alternativa cuando el uso exige una referencia de ciclo.



PIT • Point-in-Time • método usado

Se calibra con la tasa observada de un periodo reciente y maduro. Responde mejor al nivel actual de la cartera.


TTC • Through-the-Cycle • alternativa

Se calibra con una tasa de largo plazo que atraviesa distintas fases del ciclo. Es más estable, pero menos sensible al presente.

No hay una tasa universalmente correcta: el uso define el objetivo. Lo incorrecto es mezclar periodos o no documentar la decisión.

Calibración PIT: medición de la brecha inicial

Se aplica el modelo sin modificar a una muestra reciente y madura. Luego se compara la PD promedio con la tasa real del mismo periodo.



Ejemplo con OOT

- El modelo entrega una PD para cada una de las 2.004 observaciones.
- El promedio de esas probabilidades es 5,19%.
- La tasa real del mismo periodo es 5,94%.

Brecha inicial
5,19% - 5,94% = -0,75 pp

La brecha indica que el modelo está entregando un nivel promedio menor que la mora observada en ese periodo.


Calibración PIT: optimización del intercepto

El optimizador mueve un solo parámetro hasta que la diferencia entre la PD promedio calibrada y la tasa real sea cero.

$$PD_i(\delta) = \sigma[\text{logit}(PD_i) + \delta] \quad \text{y} \quad f(\delta) = \text{promedio}(PD_i(\delta)) - 5,94\% = 0$$



El optimizador usa las 2.004 PD individuales y converge en $\delta = +0,177$.



Solo cambia el intercepto. El orden de los clientes y el Gini permanecen iguales.

La curva de calibración: la PD contra la realidad, tramo a tramo

El nivel promedio puede calzar y aun así mentir por tramos. La curva lo revisa.

- ▶ Receta: ordenar por PD calibrada → 10 grupos del mismo tamaño → en cada uno, PD predicha promedio vs tasa de malos observada.
- ▶ Sobre la diagonal: la PD dice la verdad en ese tramo.
- ▶ Punto por encima de la diagonal: observado > predicho, la PD subestima (optimista). Por debajo: sobreestima (pesimista).
- ▶ Con 200 créditos por grupo, el zigzag es esperable: la señal está en el patrón sistemático, no en el punto individual.
 - La clase 5 cuantifica calibration-in-the-large, pendiente, razón O/E e intervalos de confianza. Hosmer-Lemeshow queda solo como complemento.

Calibración PIT: 10 grupos de riesgo

El promedio de OOT calza; ahora revisamos si la PD también describe cada nivel de riesgo.

Grupo (PD ↑)	DEV · PD PIT	DEV · obs.	n	OOT · PD PIT	OOT · obs.	n
1	0,06%	0,00%	333	0,06%	0,00%	201
2	0,17%	0,00%	333	0,15%	0,00%	201
3	0,35%	0,30%	332	0,34%	1,49%	201
4	0,68%	0,90%	332	0,67%	1,00%	201
5	1,19%	1,20%	332	1,18%	4,00%	200
6	2,08%	1,20%	332	2,07%	3,50%	200
7	3,64%	3,92%	332	3,64%	2,50%	200
8	6,59%	5,12%	332	6,62%	5,50%	200
9	12,29%	8,73%	332	12,87%	13,00%	200
10	30,02%	28,31%	332	31,90%	28,50%	200

OOT queda bien en promedio, pero el grupo 5 observa 4,00% frente a 1,18% predicho. No se corrige a mano: se evalúa significancia, patrón temporal y pendiente.

Qué logra –y qué no– la calibración PIT

Mover el intercepto corrige el nivel promedio del periodo elegido. No repara por sí solo un modelo deteriorado.

Sí logra

- ✓ Alinear PD promedio y tasa real
- ✓ Mantener ranking y Gini
- ✓ Actualizar el nivel al contexto reciente

No logra

- ✗ Corregir una pendiente equivocada
- ✗ Recuperar variables que perdieron señal
- ✗ Probar estabilidad fuera de la muestra

Documentar siempre: periodo, madurez del target, tasa real, PD promedio, δ exacto y periodo posterior de validación.

PARTE 2

De la PD a bandas de riesgo

¿Por qué importa?


Una política de crédito define quién se aprueba, quién se rechaza y quién pasa a revisión. Las bandas permiten aplicar esas reglas sin crear una decisión distinta para cada PD.

Qué veremos

1. Qué significa escala maestra de riesgo
2. Cómo revisar que las bandas estén ordenadas
3. Cómo conectar las bandas con el punto de corte y la estrategia

Escala maestra de riesgo (master scale)

Es una escala común que transforma distintos scores o PD en categorías fáciles de usar.



¿De dónde viene el nombre?

En riesgo de crédito se llama master scale a la escala de referencia que permite comparar categorías provenientes de distintos modelos o carteras. En español podemos decir escala maestra de riesgo.

La banda ayuda a decidir y comunicar. La PD sigue siendo el número que mide el riesgo.

Bandas de riesgo: qué debemos comprobar

Banda	Score	Odds	n	PD media	Tasa real	% histórico	% actual
A1	≥ 660	400:1	1.446	0,11%	0,14%	21,5%	18,4%
A2	640 - 660	200:1	655	0,36%	0,61%	9,7%	8,9%
B1	620 - 640	100:1	774	0,72%	1,03%	11,5%	10,8%
B2	600 - 620	50:1	829	1,41%	2,05%	12,3%	12,2%
C1	580 - 600	25:1	810	2,79%	3,70%	12,0%	12,3%
C2	560 - 580	12,5:1	744	5,43%	4,44%	11,1%	12,0%
D	540 - 560	6,25:1	628	10,16%	9,55%	9,3%	10,9%
E	< 540	–	837	26,75%	24,85%	12,4%	14,5%

Lectura rápida: A1 concentra el menor riesgo y E el mayor. Las tasas reales suben de 0,14% a 24,85%, por lo que el orden funciona.

PARTE 3

De las bandas a la decisión

¿Por qué importa?

Las bandas resumen el riesgo del mismo score. El punto de corte convierte ese orden en una regla de aprobación.

Qué veremos

1. Cómo el punto de corte separa aprobados y rechazados
2. Comparar aprobación, mora y pérdida esperada
3. Revisar qué clientes entran y salen con la nueva política

Punto de corte del score (cutoff)

Aplicamos el punto de corte sobre el mismo score calculado antes. Al moverlo, cambian el volumen aprobado y el riesgo.

Punto de corte más bajo

Se aprueban más clientes
La mora normalmente aumenta

Punto de corte más alto

Se aprueban menos clientes
La mora normalmente disminuye

500

640

Ejemplo con corte 560: se aprueban las bandas A1 a C2 y se rechazan D y E.

Pérdida esperada: llevar el riesgo a pesos

La fórmula estima cuánto dinero se pierde en promedio por el riesgo de crédito.

$$\text{Pérdida esperada} = \text{PD} \times \text{LGD} \times \text{EAD}$$

PD

Probabilidad de que el cliente incumpla

LGD

Porcentaje que se pierde si ocurre el incumplimiento

EAD

Monto expuesto cuando ocurre el incumplimiento

$$\text{\$1.000.000} \times 2\% \times 45\% = \text{\$9.000 de pérdida esperada}$$


Qué cambia cuando movemos el punto de corte

Punto de corte	Aprueba	Mora	PD media	Monto	Pérdida esp.	Pérdida / monto
500	97,8%	4,90%	4,53%	\$ 5.966 MM	122,0	2,05%
520	94,8%	4,21%	3,73%	\$ 5.776 MM	95,8	1,66%
540	86,9%	3,16%	2,44%	\$ 5.315 MM	58,3	1,10%
560	78,3%	2,10%	1,59%	\$ 4.797 MM	34,4	0,72%
580	67,3%	1,78%	0,96%	\$ 4.145 MM	18,6	0,45%
600	55,4%	1,44%	0,56%	\$ 3.375 MM	8,8	0,26%
620	43,7%	0,91%	0,34%	\$ 2.620 MM	4,0	0,15%
640	31,5%	0,63%	0,19%	\$ 1.881 MM	1,6	0,09%

Ejemplo: al pasar de 500 a 560, la aprobación baja de 97,8% a 78,3% y la mora baja de 4,90% a 2,10%.

Más aprobación normalmente implica más mora

Cada punto azul representa un punto de corte distinto medido en OOT.



Comparación a igual aprobación

90,2%

Política actual: 4,48% de mora

Scorecard: 3,48% de mora

**Mejora estimada en OOT
–1,00 punto porcentual**

El gráfico permite ver el intercambio. La tabla anterior entrega los números exactos.

El punto de corte 560 cumple las dos condiciones

Condiciones del ejemplo: aprobar al menos 75% y mantener la mora bajo 2,5%.

Punto de corte 540

86,9% aprueba
3,16% mora

No cumple mora

Punto de corte 560

78,3% aprueba
2,10% mora

Cumple ambas

Punto de corte 580

67,3% aprueba
1,78% mora

No cumple volumen

Recomendación: punto de corte 560, porque cumple simultáneamente la meta de aprobación y el límite de mora.

Swap-set: quién entra y quién sale

Comparamos dos políticas con la misma cantidad de aprobados para medir solamente la calidad del cambio.

Swap-in

La política nueva aprueba
a clientes que antes se rechazaban

Swap-out

La política nueva rechaza
a clientes que antes se aprobaban

Pregunta central

¿Los clientes que entran tienen menos riesgo que los clientes que salen?

Swap-set en OOT: el intercambio mejora la cartera

Política anterior / nueva	Nueva aprueba	Nueva rechaza
Anterior aprueba	1.680 · 3,0% malos Ambas aprueban	128 · 23,4% malos Swap-out
Anterior rechaza	128 · 9,4% malos Swap-in	68 · 38,2% malos Ambas rechazan

Entran 128 clientes con 9,4% de malos y salen 128 con 23,4%.

La cantidad aprobada se mantiene y la calidad mejora.

Reject inference: qué no sabemos de los rechazados

El modelo aprendió con créditos aprobados, porque solo en ellos observamos si pagaron o no.

Solicitudes aprobadas

Conocemos su resultado
y podemos entrenar el modelo

Solicitudes rechazadas

No sabemos si habrían pagado
porque nunca recibieron el crédito

Qué hacemos

Entramos con cautela en la población nueva, monitoreamos a quienes antes se rechazaban y recalibramos cuando tengamos evidencia real.

Lab 2 · parte B: su misión

Aplicarán la misma secuencia: medir, calibrar, validar y recién después diseñar la estrategia.

1

Elegir una ventana reciente con target maduro

2

Comparar PD promedio con tasa real del mismo periodo

3

Encontrar el δ exacto y recalculas las PD

4

Construir bandas de riesgo y probar puntos de corte

Si el periodo aún no está maduro, no se puede cerrar la tasa real: deben retroceder hasta la última ventana completamente observable.

Tres preguntas para defender la propuesta

- 1** ¿A qué tasa está calibrada la PD y qué periodo usamos?
- 2** ¿La estrategia se evaluó fuera de la muestra de desarrollo?
- 3** ¿Qué cambia al mover el punto de corte en aprobación, mora y pérdida esperada?

Si podemos responder estas preguntas con números, la decisión queda clara y trazable.

Próxima clase: ¿y cómo sé que sigue funcionando?

Jueves 10 de septiembre, 20:00 – Clase 5: Validación y monitoreo

AUC/Gini/KS y bootstrap · PSI del score y CSI · backtesting de calibración · semáforos

Entrega 2 · Lab 2 completo (partes A y B) · domingo 13 de septiembre, 23:59

Academia Bayes · academiabayes.cl · en colaboración con Nikodym Advisory

PIT y TTC: dos formas de representar el nivel de riesgo

El mismo score puede mantener el orden y usar una calibración distinta según su objetivo.

PIT

Busca reflejar el riesgo actual.
Usa información reciente y madura.

TTC

Busca un nivel promedio de largo plazo.
Cambia menos con el ciclo.

Pregunta práctica: esta PD, ¿debe representar el momento actual o un promedio de largo plazo?

Otras formas de controlar riesgo además del punto de corte

Aprobar o rechazar no es la única decisión disponible.

- 1** Usar puntos de corte distintos cuando los segmentos tienen riesgos realmente diferentes.
- 2** Cobrar un precio acorde al riesgo, siempre que el margen cubra la pérdida esperada.
- 3** Reducir el monto o el plazo para limitar la exposición.

Toda excepción debe quedar documentada y monitoreada. Un cambio temporal sin registro también cambia la política.

Preguntas para discutir

- 1 Comercial quiere punto de corte 540, pero la mora supera el límite. ¿Qué alternativas llevarían al comité?
- 2 El swap-in tiene 9,4% de malos y el swap-out 23,4%. ¿Por qué la comparación favorece el cambio?
- 3 Si el ciclo empeora con fuerza, ¿qué parte del modelo debemos recalibrar o monitorear?
- 4 ¿Cuándo conviene usar una PD PIT y cuándo una TTC?